

FINAL CHECKPOINT
ANALITIK DAN VISUALISASI DATA
“ANALISIS POPULARITAS DRAMA KOREA
BERDASARKAN RANK, POPULARITAS,
***SCREENWRITER*, DAN SUTRADARA (2015-2023)”**



Disusun oleh:

Noor Hamsyah Pratama (2509116046)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji syukur saya panjatkan kepada Tuhan Yang Maha Esa atas karunia yang telah diberikan-Nya sehingga saya dapat menyelesaikan laporan final checkpoint praktikum Analitik dan Visualisasi Data dengan judul "Analisis Popularitas Drama Korea Berdasarkan Rank, Popularitas, Screen Writer, dan Sutradara (2015–2023)" ini tepat waktu tanpa halangan dan sesuai dengan harapan.

Ucapan terima kasih sebesar-besarnya saya sampaikan kepada seluruh Asisten Laboratorium selaku pengajar pada praktikum Analitik dan Visualisasi Data yang telah membimbing saya dalam proses penyusunan laporan ini dari awal hingga akhir.

Saya menyadari bahwa dalam penyusunan laporan ini masih terdapat banyak kekurangan karena keterbatasan pengetahuan dan pengalaman yang saya miliki. Oleh karena itu, saya sangat mengharapkan kritik dan saran yang membangun guna menyempurnakan laporan ini. Semoga laporan ini dapat bermanfaat bagi semua pihak yang membutuhkan, khususnya dalam memahami penerapan analitik dan visualisasi data pada industri hiburan Korea.

Samarinda, 13 Maret 2026

DAFTAR ISI

KATA PENGANTAR.....	ii
DAFTAR ISI.....	iii
DAFTAR GAMBAR.....	v
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan Analisis	1
BAB II PEMBAHASAN.....	3
2.1 Business Understanding.....	3
2.1.1 Bussiness Objective	3
2.1.2 Asses Situation.....	4
2.1.3 Analytic Goals	5
2.1.4 Project Plan	5
2.2 Data Understanding & EDA	6
2.2.1 Import Library.....	6
2.2.2 Memuat Dataset	6
2.2.3 Data Understanding	7
2.2.4 Verifikasi Kualitas Data.....	8
2.2.5 Exploratory Data Analysis (EDA).....	12
2.3 Data Preparation.....	Error! Bookmark not defined.
2.3.1 Penanganan Tipe Data	Error! Bookmark not defined.
2.3.2 Penanganan Incosistent Values.....	Error! Bookmark not defined.
2.3.3 Penanganan Missing Values	Error! Bookmark not defined.
2.3.4 Penanganan Duplicated Values.....	Error! Bookmark not defined.
2.3.5 Penanganan Outliers	Error! Bookmark not defined.
2.3.6 Construct Data	Error! Bookmark not defined.
2.3.7 Data Reduction.....	Error! Bookmark not defined.
2.4 Visualisasi Data (Tableau).....	Error! Bookmark not defined.
2.4.1 Bar Chart.....	Error! Bookmark not defined.
2.4.2 Scatter Plot.....	Error! Bookmark not defined.

2.4.3	Box Plot	Error! Bookmark not defined.
2.4.4	Histogram.....	Error! Bookmark not defined.
2.5	Dashboard	Error! Bookmark not defined.
2.6	Hasil Analisis	Error! Bookmark not defined.
BAB III PENUTUP		17
3.1	Kesimpulan	17
3.2	Saran	17

DAFTAR GAMBAR

Gambar 2. 1 Output Struktur Data	7
Gambar 2. 2 Output Statistik Deskriptif	8
Gambar 2. 3 Output Cek Tipe Data	9
Gambar 2. 4 Output Cek Missing Values	10
Gambar 2. 5 Output Cek Outliers	11
Gambar 2. 6 Visualisasi Comparison.....	13
Gambar 2. 7 Visualisasi Composition.....	14
Gambar 2. 8 Visualisasi Distribution.....	15
Gambar 2. 9 Visualisasi Relationship	16
Gambar 2. 10 Pengecekan Tipe Data	Error! Bookmark not defined.
Gambar 2. 11 Pengecekan Ulang Tipe Data	Error! Bookmark not defined.
Gambar 2. 12 Pengecekan Missing Values.....	Error! Bookmark not defined.
Gambar 2. 13 Pengecekan Ulang Missing Values	Error! Bookmark not defined.
Gambar 2. 14 Pengecekan Outliers.....	Error! Bookmark not defined.
Gambar 2. 15 Pengecekan Ulang Outliers	Error! Bookmark not defined.
Gambar 2. 16 Bar Chart	Error! Bookmark not defined.
Gambar 2. 17 Scatter Plot	Error! Bookmark not defined.
Gambar 2. 18 Box Plot.....	Error! Bookmark not defined.
Gambar 2. 19 Histogram.....	Error! Bookmark not defined.
Gambar 2. 20 Dashboard	Error! Bookmark not defined.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri hiburan Korea Selatan, khususnya drama korea, telah mengalami pertumbuhan yang luar biasa dalam satu dekade terakhir. Fenomena Korean Wave atau Hallyu telah membawa drama korea ke panggung global, menjangkau jutaan penonton di berbagai belahan dunia melalui platform streaming internasional seperti Netflix, Viki, dan platform local lainnya. Seiring dengan meningkatnya jumlah judul yang diproduksi setiap tahunnya sejak 2015 hingga 2023, persaingan antarprodusen konten pun semakin ketat.

Di tengah persaingan yang semakin intens tersebut, platform distribusi, rumah produksi, dan pemangku kepentingan industri membutuhkan pemahaman yang mendalam mengenai faktor-faktor yang menentukan tingkat popularitas sebuah drama. Selama ini, keputusan terkait promosi dan distribusi konten masih sering didasarkan pada intuisi atau tren sesaat, tanpa didukung oleh analisis data yang terstruktur dan objektif. Akibatnya, potensi drama berkualitas tinggi kerap tidak teroptimalkan secara maksimal.

Dataset yang digunakan dalam analisis ini memuat informasi komprehensif mengenai drama Korea yang tayang pada periode 2015 hingga 2023, mencakup judul drama, tahun rilis, nama screen writer, nama sutradara, serta dua indikator popularitas utama, yaitu nilai peringkat (rank) dan nilai popularitas (popularity score). Ketersediaan data tersebut membuka peluang untuk melakukan analisis berbasis data guna mengidentifikasi pola popularitas secara objektif.

Oleh karena itu, analisis ini dilakukan untuk menjawab kebutuhan industri akan pemahaman yang lebih terstruktur mengenai popularitas Drama Korea, dengan memanfaatkan data yang tersedia sebagai dasar pengambilan keputusan yang lebih akurat, terarah, dan berbasis bukti

1.2 Tujuan Analisis

Analisis ini bertujuan untuk:

1. Menganalisis tingkat popularitas Drama Korea berdasarkan nilai peringkat (rank) dan skor popularitas (popularity) pada periode 2015–2023.

2. Mengidentifikasi sutradara yang paling banyak terlibat dalam produksi drama dengan nilai rank dan popularitas tinggi sebagai indikator kontribusi sutradara terhadap kesuksesan konten.
3. Menganalisis konsistensi kemunculan sutradara dari tahun ke tahun pada drama-drama populer untuk melihat pola popularitas yang berkelanjutan.
4. Mengidentifikasi pola kolaborasi antara screen writer dan sutradara pada drama dengan tingkat popularitas tinggi sebagai dasar rekomendasi strategi produksi konten.
5. Mendukung pengambilan keputusan bisnis yang lebih objektif dalam hal rekomendasi, distribusi, dan promosi konten Drama Korea.

BAB II

PEMBAHASAN

2.1 Business Understanding

Business Understanding merupakan tahap pertama dan paling fundamental dalam kerangka analisis data. Tahap ini bertujuan untuk membangun pemahaman yang komprehensif terhadap konteks bisnis, permasalahan yang dihadapi, serta tujuan yang ingin dicapai sebelum proses analisis data dilaksanakan.

Dalam konteks analisis ini, Business Understanding difokuskan pada industri Drama Korea periode 2015–2023. Pemahaman bisnis dibangun berdasarkan data yang tersedia, mencakup judul drama, tahun rilis, *screen writer*, sutradara, serta indikator popularitas berupa nilai peringkat dan skor popularitas. Tahap ini menjadi fondasi penting agar analisis yang dilakukan relevan, terarah, dan mampu menghasilkan rekomendasi yang dapat ditindaklanjuti secara bisnis. Business Understanding dalam analisis ini terdiri dari empat komponen utama, yaitu Business Objective, Assess Situation, Analytic Goals, dan Project Plan

2.1.1 Bussiness Objective

Business Objective menggambarkan tujuan utama yang ingin dicapai dari perspektif bisnis melalui analisis ini. Industri drama korea berkembang sangat pesat dengan ratusan judul yang dirilis setiap tahunnya, sehingga persaingan antar rumah produksi dan platform distribusi semakin ketat. Dalam kondisi tersebut, keputusan terkait pemilihan kontem yang diprioritaskan untuk dipromosikan tidak dapat lagi hanya mengandalkan panilaian subjektif atau tren sesaat yang bersifat temporer.

Dataset yang digunakan dalam analisis ini menyediakan informasi judul drama, tahun rilis, nama *screen writer*, nama sutradara, serta dua indikator popularitas utama, yaitu nilai peringkat dan skor popularitas. Ketersediaan data tersebut menjadi dasar yang kuat untuk memahami Tingkat popularitas drama secara objektif dan berbasis bukti, sehingga pengambilan keputusan bisnis dapat dilakukan dengan lebih akurat dan terstruktur.

Tujuan bisnis dari analisis ini adalah untuk:

- Memahami faktor-faktor yang memengaruhi popularitas drama korea berdasarkan data, khususnya peran *screen writer* dan sutradara sebagai kreator utama konten.

- Mengidentifikasi drama yang memiliki tingkat popularitas tinggi berdasarkan nilai *rank* dan *popularity* sebagai acuan dalam pengambilan keputusan distribusi dan promosi konten.
- Mendukung pengambilan keputusan bisnis yang lebih objektif dalam hal rekomendasi, distribusi, dan strategi promosi konten drama korea.

2.1.2 Asses Situation

Asses Situation merupakan tahap evaluasi terhadap kondisi nyata yang melatarbelakangi analisis ini, mencakup identifikasi tantangan, peluang, serta keterbatasan yang ada. Pemahaman yang menyeluruh terhadap situasi ini penting untuk memastikan bahwa analisis dilakukan dengan ekspektasi yang realistis dan pendekatan yang tepat.

Tantangan:

- Belum adanya analisis terstruktur yang secara khusus mengidentifikasi pola popularitas drama korea berdasarkan data yang tersedia.
- Kesulitan dalam menentukan sutradara atau *screen writer* yang paling dominan dalam menghasilkan drama populer, sehingga pengambilan keputusan terkait prioritas dan promosi konten masih cenderung bersifat subjektif.

Peluang:

- Dataset yang digunakan memuat informasi lengkap mengenai judul drama, tahun rilis, nama *screen writer*, nama sutradara, serta indikator popularitas berupa nilai peringkat dan skor popularitas, sehingga memungkinkan dilakukannya analisis pola popularitas secara tidak langsung namun tetap berbasis data.
- Rentang waktu dataset yang mencakup periode 2015 hingga 2023 memberikan gambaran longitudinal yang cukup panjang untuk mengidentifikasi tren dan konsistensi popularitas dari waktu ke waktu.

Keterbatasan:

- Popularitas tidak dapat diukur secara langsung dan murni dari data internal, terdapat faktor-faktor eksternal yang berpengaruh signifikan namun tidak tercakup dalam dataset, seperti tren global, viralitas media sosial, strategi pemasaran, dan penerimaan kritik.

- Interpretasi hasil analisis sangat bergantung pada asumsi dan pendekatan yang digunakan, sehingga kesimpulan yang dihasilkan bersifat indikatif dan perlu dikonfirmasi dengan data tambahan untuk pengambilan keputusan strategis.

2.1.3 Analytic Goals

Analytic Goals merupakan penjabaran tujuan bisnis ke dalam sasaran analitik yang lebih spesifik, terukur, dan dapat diimplementasikan secara teknis menggunakan data yang tersedia. Tujuan analitik ini menjadi panduan dalam menentukan metode analisis, variabel yang digunakan, serta output yang diharapkan dari proses analisis data.

Tujuan analitik dari analisis ini adalah:

- Menganalisis tingkat popularitas drama korea berdasarkan nilai peringkat dan skor popularitas untuk menghasilkan gambaran distribusi popularitas drama secara keseluruhan pada periode 2015–2023.
- Mengidentifikasi sutradara yang paling banyak terlibat dalam produksi drama dengan nilai rank dan popularity tinggi sebagai indikator kontribusi dan dominansi sutradara terhadap popularitas konten.
- Menganalisis konsistensi kemunculan sutradara dari tahun ke tahun pada drama-drama populer untuk mengidentifikasi pola popularitas yang berkelanjutan dan sutradara dengan rekam jejak yang stabil.
- Mengidentifikasi pola kolaborasi antara screen writer dan sutradara pada drama dengan tingkat popularitas tinggi sebagai dasar rekomendasi strategi produksi konten yang berpotensi sukses.

2.1.4 Project Plan

Project Plan menjabarkan tahapan-tahapan kerja yang akan dilaksanakan dalam analisis ini secara sistematis dan terstruktur. Rencana proyek disusun untuk memastikan setiap langkah analisis dilakukan secara runtut sehingga tujuan analitik dan bisnis dapat tercapai secara optimal.

- Pengumpulan dan Pemilihan Data: Mengumpulkan dan memilih data dari dataset yang memuat informasi *screen writer*, sutradara, tahun rilis, serta nilai *rank* dan *popularity* sebagai variabel utama analisis.

- **Pengolahan Data:** Melakukan proses pembersihan data (*data cleaning*) untuk menangani nilai yang hilang atau tidak konsisten, pengelompokan data berdasarkan atribut tertentu, serta transformasi data untuk mendukung analisis lebih lanjut.
- **Analisis Data:** Menganalisis hubungan antara *screen writer*, sutradara, dan indikator popularitas (*rank* dan *popularity*) menggunakan pendekatan statistik deskriptif dan eksplorasi data untuk menemukan pola yang bermakna.
- **Penarikan Kesimpulan dan Rekomendasi:** Menyimpulkan hasil analisis secara menyeluruh untuk memberikan gambaran pola popularitas drama korea, serta merumuskan rekomendasi berbasis data yang dapat digunakan sebagai dasar pengambilan keputusan bisnis.

2.2 Data Understanding & EDA

Bagian ini menjelaskan proses Data Understanding dan Exploratory Data Analysis yang dilakukan terhadap dataset drama korea. Proses ini mencakup pemuatan dataset, pemahaman struktur data, verifikasi kualitas data, dan eksplorasi visual untuk mengungkap pola serta hubungan antar variabel.

2.2.1 Import Library

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

Library pandas digunakan untuk manipulasi dan analisis data berbasis *DataFrame*. Library seaborn digunakan untuk membuat visualisasi statistik yang lebih informatif dan estetik, sedangkan matplotlib.pyplot digunakan sebagai dasar pembuatan grafik dan visualisasi data secara umum.

2.2.2 Memuat Dataset

Dataset dimuat dari Google Drive, kemudian dibaca ke dalam *DataFrame* menggunakan pandas.

```
from google.colab import drive
drive.mount('/content/drive')
path = '/content/drive/MyDrive/Colab Notebooks/korean_drama.csv'
df = pd.read_csv(path)
df
```

Google Drive di-mount terlebih dahulu agar file CSV yang tersimpan didalamnya dapat diakses dari lingkungan Google Colab. Setelah path file ditentukan, data dibaca menggunakan “pd.read_csv()” dan disimpan ke dalam

DataFrame “df”. Perintah df pada baris terakhir digunakan untuk menampilkan isi dataset. Berdasarkan output yang dihasilkan, dataset memuat kolom-kolom seperti “kdrama_id”, “drama_name”, “year”, “director”, “screenwriter”, dan kolom lainnya.

2.2.3 Data Understanding

2.2.3.1 Struktur Data

Fungsi “df.info()” digunakan untuk mendapatkan gambaran umum tentang struktur dataset.

```
df.info()
```

Output:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1752 entries, 0 to 1751
Data columns (total 17 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   kdrama_id       1752 non-null   object
1   drama_name      1752 non-null   object
2   year            1752 non-null   int64
3   director        1036 non-null   object
4   screenwriter     959 non-null    object
5   country         1752 non-null   object
6   type            1752 non-null   object
7   tot_eps         1752 non-null   int64
8   duration        1728 non-null   float64
9   start_dt        1752 non-null   object
10  end_dt          1752 non-null   object
11  aired_on        1520 non-null   object
12  org_net         1344 non-null   object
13  content_rt      1752 non-null   object
14  synopsis        1584 non-null   object
15  rank            1752 non-null   int64
16  pop             1752 non-null   int64
dtypes: float64(1), int64(4), object(12)
memory usage: 232.8+ KB
```

Gambar 2. 1 Output Struktur Data

Berdasarkan outputnya, dataset ini memiliki 1.752 baris dan 17 kolom. Kolom “director” memiliki 1.036 data non-null (716 data hilang) dan kolom “screenwriter” memiliki 956 data non-null (793 data hilang), menunjukkan bahwa kedua kolom tersebut memiliki *missing values* yang cukup besar. Lalu dari outputnya, kita bisa juga melihat tipe data dari setiap kolom.

2.2.3.2 Statistik Deskriptif

Fungsi “df.describe(include='all')” digunakan untuk menampilkan ringkasan statistik dari seluruh kolom dataset.

```
df.describe(include='all')
```

Output:

	kdrama_id	drama_name	year	director	screenwriter	country	type	tot_eps	duration	start_dt	end_dt	aired_on	org_net	content_rt	synopsis	rank	pop				
count	1752	1752	1752	000000	1036	959	1752	1752	000000	1720	000000	1752	1520	1344	1752	1584	1752	000000	1752	000000	
unique	1752	1752	1752	NaN	585	596	1	1	NaN	NaN	1307	1334	62	125	6	1584	NaN	NaN	NaN	NaN	
top	c19353bdc7a43ae9b37d302e7c9b8	Crow Building	NaN	[Ahn Gil Ho]	[Kim Eun Hye]	South Korea	Drama	NaN	NaN	2015-10-05	2020-01-23	Monday, Tuesday	Naver TV Cast	15+ Teens 15 or older	Finding a job in Seoul seems impossible for B.	NaN	NaN	NaN	NaN	NaN	
freq	1	1	NaN	9	7	1752	1752	NaN	NaN	5	5	210	209	955	1	NaN	NaN	NaN	NaN	NaN	
mean	NaN	NaN	2019.006849	NaN	NaN	NaN	NaN	18.996095	2149.791667	NaN	NaN	NaN	NaN	NaN	NaN	22247.869292	22153.746575	NaN	22247.869292	22153.746575	
std	NaN	NaN	2.3174055	NaN	NaN	NaN	NaN	25.618394	1532.133619	NaN	NaN	NaN	NaN	NaN	NaN	27688.839480	37776.993814	NaN	27688.839480	37776.993814	
min	NaN	NaN	2015.000000	NaN	NaN	NaN	NaN	1.000000	60.000000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	9.000000	1.000000	NaN	9.000000	1.000000
25%	NaN	NaN	2017.000000	NaN	NaN	NaN	NaN	8.000000	720.000000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2441.500000	915.750000	NaN	2441.500000	915.750000
50%	NaN	NaN	2019.000000	NaN	NaN	NaN	NaN	12.000000	1800.000000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	6265.500000	3698.500000	NaN	6265.500000	3698.500000
75%	NaN	NaN	2021.000000	NaN	NaN	NaN	NaN	16.000000	3600.000000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	48204.500000	12030.250000	NaN	48204.500000	12030.250000
max	NaN	NaN	2023.000000	NaN	NaN	NaN	NaN	150.000000	9180.000000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	99999.000000	99999.000000	NaN	99999.000000	99999.000000

Gambar 2. 2 Output Statistik Deskriptif

Berdasarkan output statistik deskriptif, dataset ini memiliki total 1.752 baris data dengan 17 kolom. Dari hasil ini dapat disimpulkan bahwa beberapa kolom memiliki missing values, yaitu kolom screenwriter dengan 793 data hilang, kolom director dengan 716 data hilang, kolom org_net dengan 408 data hilang, kolom aired_on dengan 232 data hilang, kolom synopsis dengan 168 data hilang, dan kolom duration dengan 24 data hilang. Hal ini menunjukkan bahwa kolom director dan screenwriter merupakan kolom yang paling banyak kehilangan data dan memerlukan penanganan khusus sebelum analisis dilanjutkan.

Selain itu, statistik deskriptif juga memberikan gambaran distribusi pada kolom numerik. Sebagai contoh, kolom rank memiliki rata-rata 22.247 dengan median 6.265 dan standar deviasi 27.688, selisih besar antara mean dan median menunjukkan distribusi yang tidak merata, di mana hanya sedikit drama yang memiliki peringkat sangat tinggi. Begitu pula kolom pop dengan rata-rata 22.153, median 3.698, dan standar deviasi tertinggi sebesar 37.776, mengindikasikan bahwa popularitas drama sangat bervariasi dan didominasi oleh sebagian kecil judul yang sangat populer.

2.2.4 Verifikasi Kualitas Data

2.2.4.1 Cek Tipe Data

```
df.dtypes
```

Output:

0	
kdrama_id	object
drama_name	object
year	int64
director	object
screenwriter	object
country	object
type	object
tot_eps	int64
duration	float64
start_dt	object
end_dt	object
aired_on	object
org_net	object
content_rt	object
synopsis	object
rank	int64
pop	int64
dtype: object	

Gambar 2. 3 Output Cek Tipe Data

Kolom bertipe object mencakup kolom-kolom yang bersifat kategorikal atau teks, seperti 'kdrama_id', 'drama_name', 'screenwriter', 'country', 'type', 'start_dt', 'end_dt', 'aired_on', 'org_net', 'content_rt', dan 'synopsis'. Kolom bertipe integer (int64) mencakup 'year', 'tot_eps', 'rank', dan 'pop', sedangkan kolom 'duration' bertipe float (float64) karena dapat bernilai decimal.

2.2.4.2 Cek Inconsistent Values

Pengecekan Inconsistent Values dilakukan pada setiap kolom menggunakan fungsi "df['kolom'].unique()".

```
print(df['kdrama_id'].unique())
print(df['drama_name'].unique())
print(df['director'].unique())
print(df['screenwriter'].unique())
print(df['country'].unique())
print(df['type'].unique())
print(df['start_dt'].unique())
print(df['end_dt'].unique())
print(df['aired_on'].unique())
print(df['org_net'].unique())
print(df['content_rt'].unique())
print(df['synopsis'].unique())
```

Dari hasil pengecekan, ditemukan beberapa ketidakkonsistenan: (1) Kolom director ditemukan inconsistent value pada nama "Hwang Gyung Sung" yang memiliki double space. (2) Kolom screenwriter ditemukan inconsistent value pada nama "Shin So Young" yang juga memiliki double space. (3) Kolom start_dt dan end_dt memiliki format tanggal yang tidak seragam, sebagian menggunakan format 'Aug 2, 2023', sebagian lain menggunakan '2023-07-05', bahkan ada yang hanya berisi tahun saja seperti '2015'. Ketidakkonsistenan ini perlu ditangani dengan menyamakan format menjadi yyyy-mm-dd. Sementara itu, kolom-kolom lain seperti kdrama_id, drama_name, country, type, aired_on, org_net, content_rt, dan synopsis tidak ditemukan adanya inconsistent values.

2.2.4.3 Cek Missing Values

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Output:

	Null Ratio in %
kdrama_id	0.000000
drama_name	0.000000
year	0.000000
director	40.867580
screenwriter	45.262557
country	0.000000
type	0.000000
tot_eps	0.000000
duration	1.369863
start_dt	0.000000
end_dt	0.000000
aired_on	13.242009
org_net	23.287671
content_rt	0.000000
synopsis	9.589041
rank	0.000000
pop	0.000000

Gambar 2. 4 Output Cek Missing Values

Kode ini menghitung persentase missing values pada setiap kolom dengan membagi jumlah nilai null “df.isna().sum()” dengan total baris “len(df)”, lalu dikalikan 100 untuk mendapatkan persentase.

Kolom screenwriter (45,26%) dan director (40,87%) merupakan dua kolom dengan missing values tertinggi, sehingga memerlukan perhatian

khusus dalam analisis. Kolom rank, pop, year, country, type, tot_eps, start_dt, end_dt, dan content_rt tidak memiliki missing values (0%) sehingga sangat andal untuk digunakan secara langsung.

2.2.4.4 Cek Duplicated Values

```
df[df.duplicated()]
```

Kode “df[df.duplicated()]” digunakan untuk memfilter baris-baris yang merupakan duplikat dari baris lain di dataset. Output yang dihasilkan adalah DataFrame kosong yang berarti tidak ada baris yang terduplikasi dalam dataset ini. Hal ini menunjukkan kualitas data yang baik dari sisi keunikan data, sehingga tidak diperlukan penanganan duplikasi lebih lanjut.

2.2.4.5 Cek Outliers

```
results = []
cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)
```

Output:

Kolom	Persentase Outliers
year	0.000000
tot_eps	13.641553
duration	0.057078
rank	0.000000
pop	18.892694

Gambar 2. 5 Output Cek Outliers

Deteksi outlier dilakukan menggunakan metode IQR (Interquartile Range). Nilai Q1 (persentil ke-25) dan Q3 (persentil ke-75) dihitung untuk setiap kolom numerik, lalu IQR diperoleh dari selisih Q3 dan Q1. Batas bawah ditetapkan pada $Q1 - 1.5 \times IQR$ dan batas atas pada $Q3 + 1.5 \times IQR$. Data yang berada di luar rentang tersebut dikategorikan sebagai outlier.

Kolom pop menunjukkan persentase outlier tertinggi sebesar 18,89%, yang mengindikasikan adanya drama dengan nilai popularitas yang jauh di atas atau di bawah rata-rata mayoritas. Kolom tot_eps juga menunjukkan outlier yang signifikan (13,64%), kemungkinan disebabkan adanya drama dengan jumlah episode sangat banyak. Kolom year dan rank tidak memiliki outlier sama sekali, sedangkan duration hanya memiliki outlier yang sangat kecil (0,06%).

2.2.5 Exploratory Data Analysis (EDA)


2.2.5.1 Comparison (Perbandingan)

Kode ini menghitung frekuensi kemunculan setiap tahun menggunakan “value_counts()”, kemudian memvisualisasikannya dalam bentuk bar chart menggunakan seaborn. Palette ‘twilight’ digunakan untuk memberikan variasi warna pada setiap batang

```
tahun_drama = df['year'].value_counts()

plt.figure(figsize=(10,6))
sns.barplot(x=tahun_drama.index,y=tahun_drama.values,hue=tahun_drama.index,palette='twilight',legend=False)
plt.title('Jumlah Drama Berdasarkan Tahun Rilis')
plt.xlabel('Tahun Rilis')
plt.ylabel('Jumlah')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

Output:



Gambar 2. 6 Visualisasi Comparison

Berdasarkan visualisasi yang dihasilkan, terdapat pola peningkatan produksi yang stabil dari tahun 2015 hingga mencapai puncaknya pada 2019. Tahun 2020 mengalami penurunan yang kemungkinan disebabkan oleh gangguan produksi akibat pandemi. Selanjutnya terjadi pemulihan signifikan pada 2021 yang menjadi titik produksi tertinggi, namun kembali menurun pada 2022–2023.


2.2.5.2 Composition (Komposisi)

Kode ini mengelompokkan data berdasarkan kolom 'content_rt', menjumlahkan total episode ('tot_eps') untuk setiap kategori rating, lalu mengambil tiga kategori teratas untuk divisualisasikan dalam pie chart.

```
rate_eps = df.groupby('content_rt')['tot_eps'].sum().sort_values(ascending=False)
rate_eps_top3 = rate_eps.head(3)

plt.figure(figsize=(10, 8))
rate_eps_top3.plot(kind='pie', autopct='%1.1f%%', startangle=140,
colors=plt.cm.Pastel2.colors)
plt.title('Proporsi Total Episode Berdasarkan Content Rating (Top 3)')
plt.ylabel("")
plt.axis('equal')
plt.show()
```

Output:



Gambar 2. 7 Visualisasi Composition


Berdasarkan visualisasi, kategori 15+ (Teens 15 or older) mendominasi dengan proporsi sekitar 54,5%, diikuti Not Yet Rated sekitar 30,9%, dan kategori 13+ sekitar 8,0%. Hal ini mengindikasikan bahwa industri drama Korea lebih banyak memproduksi konten dengan segmentasi usia 15 tahun ke atas sebagai target pasar utama.

2.2.5.3 Distribution (Distribusi)

Kode ini menggunakan “sns.histplot()” dengan parameter “kde=True” untuk menampilkan histogram sekaligus kurva estimasi kepadatan kernel (KDE). Histogram memperlihatkan frekuensi kemunculan setiap rentang durasi, sedangkan garis KDE memperhalus pola distribusi tersebut.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['duration'], bins=20, kde=True)
plt.title('Distribusi Durasi Drama')
plt.xlabel('durasi')
plt.ylabel('Frekuensi')
plt.show()
```

Output:



Gambar 2. 8 Visualisasi Distribution

Berdasarkan visualisasi yang dihasilkan, distribusi durasi drama bersifat right-skewed (miring ke kanan), artinya mayoritas drama memiliki durasi yang terkonsentrasi pada rentang tertentu namun terdapat beberapa drama berdurasi sangat panjang yang membentuk ekor panjang di sisi kanan grafik.

2.2.5.4 Relationship (Hubungan)

Kode ini menghitung korelasi antara kolom-kolom numerik (year, tot_eps, duration, rank, pop) menggunakan “.corr()”, kemudian memvisualisasikannya dalam bentuk heatmap berwarna menggunakan “sns.heatmap()”. Parameter “annot=True” menampilkan nilai korelasi pada setiap sel, “cmap='YlGnBu'” memberikan gradasi warna, dan “fmt='.2f'” memformat nilai menjadi dua angka desimal.

```
plt.figure(figsize=(8, 6))

sns.heatmap(data=df[['year', 'tot_eps', 'duration', 'rank', 'pop']].corr(),

            annot=True,


            cmap='YlGnBu',

            fmt='.2f')

plt.title('Korelasi Antar Kolom Numerik')

plt.show()
```

Output:



Gambar 2. 9 Visualisasi Relationship

Berdasarkan heatmap yang dihasilkan, hubungan paling kuat terdapat antara kolom 'rank' dan 'pop' dengan nilai korelasi positif sebesar 0,77, menunjukkan bahwa drama dengan peringkat tinggi cenderung memiliki skor popularitas yang juga tinggi. Selain itu, ditemukan korelasi negatif yang cukup kuat antara 'duration' dan 'rank' (-0,53) serta 'duration' dan 'pop' (-0,49), yang mengindikasikan bahwa drama berdurasi lebih panjang cenderung berasosiasi dengan nilai rank dan popularitas yang lebih rendah. Variabel lain seperti 'year' dan 'tot_eps' menunjukkan korelasi yang sangat lemah terhadap indikator popularitas.

BAB III

PENUTUP

3.1 Kesimpulan

3.2 Saran